

支持向量机


支持向量机

- 三个特征：间隔、对偶、核技巧
- 三类问题：
 - hard-margin SVM: 线性可分问题
 - soft-margin SVM: 线性不可分问题，可以允许一些分类错误
 - kernel SVM: 非线性问题
- 支持向量机的模型：



$$y = \mathbf{w}^T \mathbf{x} + b$$

支持向量机的基本思想


- 感知机算法得到的三条直线:



- 样本点附近的圆形区域越大，表示分类直线对测量数据误差的容忍性越高



- 用圆形区域表示分类线能够容忍多少误差，相当于计算点到直线的距离。



- 基本思想：找到一条最好的直线，离样本点距离足够的大
- 间隔(margin)越大越好

SVM模型建立

- 数据集可以描述为:

$$D = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, \mathbf{x}_i \in \mathbf{R}^p, y_i \in \{1, -1\}$$

- 原模型1:

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & margin(\mathbf{w}, b) \\ s.t. \quad & \mathbf{w}^T \mathbf{x}_i + b > 0, \quad y_i = 1 \\ & \mathbf{w}^T \mathbf{x}_i + b < 0, \quad y_i = -1 \quad (i = 1, 2, \dots, N) \end{aligned}$$

- 原模型2:

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & margin(\mathbf{w}, b) \\ s.t. \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) > 0 \quad (i = 1, 2, \dots, N) \end{aligned}$$

- 定义间隔:

$$\text{margin}(\mathbf{w}, b) = \min_i \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|}$$

- 原模型3:

$$\begin{array}{ll} \max_{\mathbf{w}, b} & \min_i \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|} \\ \text{s.t.} & y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0 \quad (i = 1, 2, \dots, N) \end{array}$$

- 引理1. 若 (\mathbf{w}^*, b^*) 是原模型3的解, 那么对任意的 $r > 0$, $(r\mathbf{w}^*, rb^*)$ 仍是该模型的解

证明:

$$\frac{|r\mathbf{w}^{*T}\mathbf{x}_i + rb^*|}{\|r\mathbf{w}^*\|} = \frac{|\mathbf{w}^{*T}\mathbf{x}_i + b|}{\|\mathbf{w}^*\|}$$

$$y_i((r\mathbf{w}^*)^T\mathbf{x}_i + rb^*) > 0 \Leftrightarrow y_i(\mathbf{w}^{*T}\mathbf{x}_i + b^*) > 0 \quad \square$$

- 则我们约束 (\mathbf{w}, b) , 使得 $\min_i |\mathbf{w}^T\mathbf{x}_i + b| = 1$

- 原模型4:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad (i = 1, 2, \dots, N) \end{aligned}$$

- 这是一个凸优化问题, 也是一个二次规划问题(QP问题), 包含 $p + 1$ 个优化变量, N 项约束

- 例1. 假设平面上有四个点，两个正类，两个负类：

$$X = \begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 2 & 0 \\ 3 & 0 \end{bmatrix} \quad Y = \begin{bmatrix} -1 \\ -1 \\ 1 \\ 1 \end{bmatrix}$$

$$\begin{array}{rcl} -2w_1 & -2w_2 & -b \geq 1 \quad (1) \\ 2w_1 & & -b \geq 1 \quad (2) \\ & 2w_1 & +b \geq 1 \quad (3) \\ & 3w_1 & +b \geq 1 \quad (4) \end{array}$$

$$\left\{ \begin{array}{l} (i) \& (iii) \Rightarrow w_1 \geq +1 \\ (i) \& (ii) \Rightarrow w_2 \leq -1 \end{array} \right\} \Rightarrow \frac{1}{2} \mathbf{w}^T \mathbf{w} \geq 1$$

$$w_1 = 1, w_2 = -1, b = -1$$

$$g(\mathbf{x}) = \text{sign}(x_1 - x_2 - 1)$$

对偶

- 线性支持向量机的拉格朗日函数为：

$$L(\mathbf{w}, b, \lambda) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^N \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b))$$

- 对偶问题：

$$\begin{aligned} \max_{\lambda} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^N \lambda_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) \\ \text{s.t.} \quad & \lambda_i \geq 0, i = 1, 2, \dots, N. \end{aligned}$$

- 利用KKT条件中的稳定性条件可得：

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^N \lambda_i y_i = 0$$

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^N \lambda_i y_i \mathbf{x}_i$$

代入对偶问题可得对偶问题2：

$$\begin{aligned} \min_{\lambda} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \lambda_i \lambda_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^N \lambda_i \\ \text{s.t.} \quad & \lambda_i \geq 0, i = 1, 2, \dots, N. \\ & \sum_{i=1}^N \lambda_i y_i = 0 \end{aligned}$$

这也是一个凸优化问题，也是一个二次规划问题(QP问题)，包含 N 个优化变量， $N + 2$ 项约束

- 其他KKT条件:
 - 主问题可行: $1 - y_i(\mathbf{w}^T \mathbf{x}_i + b) \leq 0$
 - 对偶问题可行: $\lambda_i \geq 0$
 - 互补松弛: $\lambda_i(1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) = 0$
- 支持向量: 对偶变量 $\lambda_i > 0$ 对应的样本
- 支持向量集 SV : 所有支持向量组成的集合
- 引理2. 线性支持向量机中, 支持向量是距离划分超平面最近的样本, 落在最大间隔边界上。
- 证明: 由互补松弛条件可知: 当 $\lambda_i > 0$ 时, $1 - y_i(\mathbf{w}^T \mathbf{x}_i + b) = 0$ \square

仅利用支持向量 $\lambda_i \in SV$, 可计算: $\mathbf{w} = \sum_{i \in SV} \lambda_i y_i \mathbf{x}_i, b = y_i - \mathbf{w}^T \mathbf{x}_i$.

- 线性支持向量机的假设函数可表示为:

$$h(\mathbf{x}) = \text{sign}\left(\sum_{i \in SV} \lambda_i y_i \mathbf{x}_i^T \mathbf{x} + b\right)$$

- 线性支持向量机的损失函数可表示为:

$$Loss(\mathbf{w}, b) = \sum_i \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$$